SAKARYA UYGULAMALI BİLİMLER ÜNİVERSİTESİ

Elektrik-Elektronik Mühendisliği Bölümü

Yapay Zekaya Giriş

DÖNEM PROJESİ — FAZ 1 RAPORU

Deep Learning-Based Automatic Modulation Classification (AMC) Using Noisy I/Q Signal Data

Derin Öğrenme Tabanlı Gürültülü I/Q Sinyal Verisi ile Otomatik Modülasyon Sınıflandırması

Proje Aşaması	Faz 1 — Problem Tanımlama
Akademik Yıl	2025–2026 Bahar Dönemi
Bölüm	Elektrik-Elektronik Mühendisliği
Ders	Yapay Zekaya Giriş
Öğrenci Numarası	23010104005

1. Problem Tanımı

1.1 Problem İfadesi

Radyo frekansı (RF) iletişiminde, bir alıcı birimin gelen sinyalin hangi modülasyon şeması ile gönderildiğini bilmesi gerekmektedir. Geleneksel yaklaşımlarda bu bilgi; iletim parametrelerinin önceden bilinmesine ya da uzman analistlerin elle yürüttüğü kurala dayalı sınıflandırma süreçlerine dayanmaktadır. Ancak gerçek dünya RF ortamları, gürültü, çok yollu yayılım (multipath fading) ve çeşitli kanal bozulmaları nedeniyle bu yöntemleri yetersiz kılmaktadır.

Bu proje, Otomatik Modülasyon Sınıflandırması (Automatic Modulation Classification — AMC) problemini denetimli çok-sınıflı sınıflandırma (supervised multi-class classification) çerçevesinde ele almaktadır. Sisteme ham I/Q (In-phase / Quadrature) sinyal örnekleri girdi olarak verilmekte; sistem bu örnekleri önceden belirlenmiş modülasyon sınıflarından birine otomatik olarak atamaktadır.

Boyut	Detay
Giriş (Input)	Ham I/Q sinyal örnekleri — 2 kanal (I ve Q) x 128 zaman adımı
Çıkış (Output)	Modülasyon sınıfı: AM-DSB, AM-SSB, WBFM, BPSK, QPSK, 8PSK, 16QAM, 64QAM, CPFSK, PAM4, GFSK
Temel Zorluk	-20 dB ile +18 dB arasındaki SNR seviyeleri boyunca guvenilir siniflandirma
Problem Türü	Denetimli çok-sınıflı sınıflandırma (11 sınıf)

Tablo 1.1: Problem Tanımı Özeti

I ve Q bileşenleri, karmaşık bir taban bandı sinyalinin iki dik (ortogonal) bileşenidir; bu iki kanal birlikte sinyalin hem genliğini hem de fazını tam olarak tanımlar. Bir RF sinyalinin modülasyon türü, I ve Q kanallarının zaman içindeki değişim örüntüsünde gizlidir. Derin öğrenme modelleri, bu örüntüleri elle özellik çıkarımı yapmadan doğrudan ham veriden öğrenme kapasitesine sahiptir; bu da AMC problemi için özellikle uygun bir yaklaşım haline gelmektedir.

1.2 Motivasyon ve Kapsam

Radyo spektrumu; savunma sistemleri, sivil telekomünikasyon, bilişsel radyo ve spektrum izleme gibi kritik uygulamalar için kıt ve stratejik bir kaynaktır. Dinamik spektrum yönetimi ve elektronik harp senaryolarında modülasyon türünün otomatik, hızlı ve güvenilir biçimde belirlenmesi büyük önem taşımaktadır. Bu proje, derin öğrenme yöntemlerinin AMC problemine uygulanabilirliğini araştırmakta; akademik açıdan kabul görmüş RadioML veri kümeleri üzerinde deneysel bir çalışma yürütmektedir.

Projenin kapsamı, modülasyon türü sınıflandırması ile sınırlıdır. Taşıyıcı frekans kestirimi, bant genişliği tahmini ve kanal dengeleme bu çalışmanın dışındadır.

2. Paydaş Analizi

Paydaş analizi; sistemden kimin etkileneceğini, kimin bu sistemi kullanacağını ve başarı kriterlerinin kime göre tanımlandığını netleştirmeye yarar. Aşağıdaki tabloda projenin birincil ve ikincil paydaşları, ilgi alanları ve projeyle ilişkileri açıklanmaktadır.

Paydaş	İlgi / Beklenti	Proje ile İlişkisi	Öncelik
Savunma / Elektronik Harp	Düşman sinyal türlerinin gerçek zamanlı tespiti	AMC, elektronik harp (EW) sistemlerinin temel bileşenidir	**Yüksek**
Spektrum Düzenleyiciler (BTK vb.)	Yetkisiz / anormal sinyal iletimlerinin tespiti	Otomatik sınıflandırma manuel denetim maliyetini azaltır	**Orta**
Telekom Mühendisleri / 5G-SDR Araştırmacıları	Adaptif modülasyon ve bağlantı kalitesi iyileştirme	Gerçek zamanlı AMC ile SNR'ye göre uyarlamalı mod seçimi	**Orta**
Akademik Araştırmacılar	Yeni derin öğrenme mimarilerinin kıyaslanması	RadioML veri kümeleri standart kıyaslama ortamıdır	**Yüksek**
Proje Grubu (Öğrenci)	EE + YZ bilgisinin pratik entegrasyonu; akademik not	Geliştirici, test edici, raporlayan	**Birincil**

Tablo 2.1: Paydaş Analizi

Bu proje, birincil hedef paydaşı olarak akademik araştırma ve öğrenim bağlamını benimsemektedir. Savunma ve telekomünikasyon paydaşları motivasyon kaynağı olarak değerlendirilmekte; ancak bu proje kapsamında doğrudan hizmet edilmemektedir.

3. Başarı Metrikleri

Projenin başarısını ölçmek için aşağıdaki metrikler tanımlanmıştır. Her metrik, neden seçildiğine dair kısa bir gerekçe ile birlikte verilmiştir.

Metrik	Açıklama	Hedef Değer	Öncelik
Genel Doğruluk (Accuracy)	Tüm SNR seviyeleri dahil doğru sınıflandırılan örnek oranı	**>= %60 (tüm SNR)**	**Birincil**
Yüksek-SNR Doğruluğu	SNR >= 0 dB olan örneklerde doğruluk oranı	**>= %85**	**Birincil**
Makro F1-Skoru	Her sınıfı esit agirlikta degerlendirir; sinif dengesizligine karsi adil olcum	**>= 0.60**	**Birincil**
SNR'ye Gore Dogruluk Egrisi	Farkli SNR seviyelerinde performansin gorsellestirilmesi; temel AMC tani grafigi	Net egri + yorumlama	**Birincil**
Karisiklik Matrisi	Hangi modulasyon siniflarinin birbirleriyle karistirildiginin analizi	11x11 matris + yorum	**Ikincil**
Egitim Suresi	GTX 1650 GPU uzerinde model basina egitim suresi	< 2 saat / model	**Ikincil**
Model Karsilastirmasi	Baseline (RF) vs CNN vs DL hibrit modelin sistematik karsilastirmasi	**>= 3 model**	**Zorunlu (Ders)**

Tablo 3.1: Basari Metrikleri ve Hedef Degerler

Not: Genel dogruluk icin belirlenen %60 hedefi, düşük SNR seviyelerindeki (-20 dB ile -10 dB arasi) örneklerin neredeyse tum yontemler tarafindan doğru sınıflandırılması gerçeğini yansitmaktadir. Bu durum beklenen ve normal bir davranistir; SNR'ye gore dogruluk eğrisi bu etkiyi acikca gösterecektir.

4. Kisitlar

4.2 Kapsam Kisitlari

- Bu proje yalnizca modulasyon turu siniflandirmasini kapsamaktadir; tasiyici frekans kestirimi, bant genisligi tahmini ve kanal dengeleme kapsam disindir.
- Transfer ogrenmesi (2016 -> 2018) proje kapsami disindir; yalnizca sinirli karsilastirma yapilacaktir.
- Gercek zamanli sinyal isleme altyapisi bu proje kapsaminda gelistirilmeyecektir; Streamlit demosu cevrimdisi (offline) calisacaktir.
- Model, yalnizca RadioML veri kumesinde tanimli 11 modulasyon sinifi icin egitilecektir.

4.3 Akademik Kisitlar

- Proje, dersin belirlediği 6 fazli YZ proje yasam dongusu cercevesinde yurutulecektir (CRISP-DM + MLOps).
- En az 3 farkli model yaklasiminin karsilastirilmasi ders kosulunun zorunlu gerekliligidir.
- Hafta 12'ye kadar calisan demo, minimum 15 sayfa IEEE formatli teknik rapor ve GitHub deposu teslim edilecektir.
- Tum kodun aciklanabilir ve ozgun olmasi gerekmektedir.

5. Literatur Ozeti

Bu bolumde, AMC alanindaki temel referans calismalar ozetlenmektedir. Bu calismalar; veri kumesi secimini, kullanilan mimarileri ve basari metriklerinin belirlenmesini dogrudan etkilemistir.

Calisma (Yazar, Yil)	Yayin Yeri	Temel Katki	Bu Proje ile Iliskisi
O'Shea & West (2016) — Radio Machine Learning Dataset Generation with GNU Radio	GNU Radio Symposium	RadioML 2016.10a veri kumesini tanitmistir. CNN tabanli siniflandiricilar; uzman ozellik tabanli yontemleri orta-yuksek SNR seviyelerinde gecmistir.	Birincil veri kumesi referansi; temel kiyaslama degerleri bu calismadan alinmistir.
O'Shea, Roy & Clancy (2018) — Over-the-Air Deep Learning Based Radio Signal Classification	IEEE JSTSP	RadioML 2018.01A veri kumesini tanitmis; ResNet tarzı ağların yuksek SNR'de ~%93 dogruluga ulasabilecegini gostermistir.	Ikincil veri kumesi referansi; optimizasyon asamasinda hedef mimari esin kaynagi.
West & O'Shea (2017) — Deep Architectures for Modulation Recognition	IEEE DySPAN	CNN, LSTM ve CNN+LSTM hibrit mimarilerini RadioML verisi uzerinde karsilastirmis; hibrit yapilarin her ikisinden de ustun oldugunu gostermistir.	Model karsilastirma asamasinin dogrudan referansi; CNN ve CNN+LSTM yaklasimi bu calismadan esinlenilecek.
Liu et al. (2017) — Deep Neural Network Architectures for Modulation Classification	WCSP 2017	AMC icin artik baglantili (residual) mimarilerin kullanimi onerilmis; derin aglarda egitim istikrarini artirmistir.	Optimizasyon asamasinda artik baglanti uygulamasi icin referans alinacak.

Tablo 5.1: Literatur Ozeti

5.1 Literaturden Cikan Temel Bulgular

Incelenen calismalar, asagidaki dort temel bulguyu ortaklasa desteklemektedir:

- **Dusuk SNR'de siniflandirma siniri:** -10 dB'nin altindaki SNR seviyelerinde tum yontemlerin performansi rastgele tahminden yalnizca hafifce ustundur. Bu fiziksel bir sinirdir, yontem basarisizligi degildir.
- **Ham I/Q verisi yeterlidir:** CNN tabanli modeller, elle ozellik muhendisligi gerektirmeksizin ham I/Q verisi uzerinde rekabetci performans gostermektedir.
- **Hibrit mimariler daha gucludur:** CNN+LSTM kombinasyonu, I/Q sinyalinin hem yerel oruntülerini (CNN) hem de zamansal bagimlilikları (LSTM) yakalayarak tek basina CNN veya LSTM'den daha iyi sonuc vermektedir.
- **SNR egrisi temel tani aracidir:** Yalnizca genel dogruluk degeri yaniltici olabilir; SNR'ye gore dogruluk egrisi modelin gercek guc ve zayiflik noktalarini ortaya koyar.

5.2 Bu Projenin Literatur'deki Konumu

Bu proje, yeni bir yontem onermek yerine mevcut yontemleri standart bir kiyaslama ortaminda sistematik olarak karsilastirmayi hedeflemektedir. Uc model yaklasimi (Random Forest baseline, CNN ve CNN+LSTM hibrit) ayni veri kumesi uzerinde egitilecek ve degerlendirilecek; elde edilen sonuclar literaturdeki referans degerlerle tartisılacaktir.

6. Veri Kumesi Genel Bakis ve Kullanim Plani

Ozellik	RadioML 2016.10a (Birincil)	RadioML 2018.01A (Karsilastirmali)
Dosya Boyutu	~55 MB (.pkl)	~21 GB (.hdf5)
Toplam Ornek Sayisi	220.000 (11 sinif x 20 SNR x 1.000 ornek)	~2.5 Milyon
Sinyal Uzunlugu	128 zaman adimi	1.024 zaman adimi
SNR Araligi	-20 dB ile +18 dB (2 dB adim, 20 seviye)	-20 dB ile +30 dB (daha genis aralik)
Format	Python pickle (.pkl) — anahtar: (modulasyon, SNR)	HDF5 (.hdf5) — moduler yapi
Projede Kullanim Rolu	EDA (tam) + Model egitimi + Degerlendirme	Yapisal karsilastirma EDA + Sinirli orneklem degerlendirme
RAM'e Yuklenebilirlik	Evet (16 GB RAM'de sorunsuz)	Hayir — ornekleme zorunludur

Tablo 6.1: Veri Kumesi Karsilastirmasi

RadioML 2016.10a veri kumesi, GNU Radio yazilim tanimli radyo simulatoru kullanilarak uretilmis sentetik bir veri kumesidir. Her (modulasyon, SNR) cifti icin 1000 ornek barindirmakta olup her ornek 2 x 128 boyutlu bir dizi (I kanali ve Q kanali) bicimindedir. Veri kumesinin sentetik niteligi, gercek kanal etkilerini tam olarak yansitmamakla birlikte; kontrollü bir arastirma ortami saglamasi ve alandaki standart kiyaslama niteligi tasiması nedeniyle bu proje icin uygun bir secimdir.

7. Sonuc ve Bir Sonraki Adim

Bu raporda, AMC projesinin problem tanimi, paydas analizi, basari metrikleri, kisitlar ve ilgili literatur ozeti sunulmustur. Proje metodolojisi, ders kilavuzunda tanimlanan yapay zeka proje yasam dongusu (CRISP-DM + MLOps) cercevesinde tasarlanmis ve tum karar noktalari geciklendirilmistir.

Tamamlanan Asamas

- Faz 1: Problem Tanimlama — Tamamlandi
- Faz 2: Veri Envanteri — Tamamlandi

Bir Sonraki Adim: Kesifsel Veri Analizi (EDA)

EDA asamasinda asagidaki gorevler sirasiyla gerceklestirilecektir:

- RadioML 2016.10a veri kumesinin yapisal incelenmesi (tip, sekil, anahtarlar)
- Sinif ve SNR dagiliminin gorsellestirilmesi (denge analizi)
- Her modulasyon turu icin ornek dalga formu cizimi
- I ve Q kanallarinin istatistiksel ozeti
- RadioML 2018.01A icin sinirli yapisal karsilastirma EDA
- Her iki veri kumesinin boyut, sinif ve SNR acisindan karsilastirilmasi

EDA calismalar, Jupyter Notebook ortaminda yurutulecek ve sonuclar 01_eda_2016_structure_inspection.ipynb dosyasinda belgelenecektir. Haftalık teslim takvimi gozetilerek EDA raporu Hafta 3 teslim tarihinde hazir olacaktir.

— Sakarya Uygulamali Bilimler Universitesi | EEF | Yapay Zekaya Giris | 2024-2025 —