SAKARYA UYGULAMALI BİLİMLER ÜNİVERSİTESİ

Elektrik-Elektronik Mühendisliği Bölümü

Yapay Zekaya Giriş — 2024-2025 Bahar Dönemi

FAZ 2 — VERİ TOPLAMA & ETİKETLEME RAPORU

Proje Başlığı:

Derin Öğrenme Tabanlı Otomatik Modülasyon Sınıflandırması (AMC)

Gürültülü I/Q Sinyal Verisi Kullanılarak

Alan	Bilgi
Ders Kodu	EEF / Yapay Zekaya Giriş
Akademik Yıl	2025 – 2026 Bahar Dönemi
Faz	2 — Veri Toplama & Etiketleme (Hafta 2)
Teslim Türü	Veri Envanteri + Etiketleme/Temizleme Planı + Veri Sözlüğü
Birincil Veri Seti	RadioML 2016.10a
İkincil Veri Seti	RadioML 2018.01A (karşılaştırmalı EDA için)

1. Giriş ve Faz Amacı

Bu rapor, AMC projesinin ikinci fazını (Faz 2 — Veri Toplama & Etiketleme) kapsamaktadır. Faz 1'de (Problem Tanımlama) ortaya konan problem çerçevesi ve başarı metrikleri ışığında, bu fazda şu dört ana görev gerçekleştirilmiştir:

- Veri kaynaklarının tespiti ve erişim yollarının belgelenmesi
- Ham verinin toplanması ve depolama yapısının kurulması
- Etiketleme ve temizleme planının oluşturulması
- Veri sözlüğünün hazırlanması

RadioML veri setleri sentetik (yapay olarak üretilmiş) olduğu için geleneksel anlamda 'veri toplama' yapılmamaktadır; bunun yerine resmi kaynaklardan indirme, yapısal doğrulama ve belgeleme süreci uygulanmaktadır.

2. Veri Kaynaklarının Tespiti

2.1 Birincil Kaynak — RadioML 2016.10a

Özellik	Detay
Tam Adı	RadioML 2016.10a (RML2016.10a)
Üretici	DeepSig Inc. / Timothy J. O'Shea
Yayın Yılı	2016
Üretim Aracı	GNU Radio — açık kaynak yazılım tabanlı radyo platformu
Format	Python Pickle (.pkl) — Python 2 latin1 kodlaması
Dosya Adı	RML2016.10a_dict.pkl
Boyut	~600 MB
Lisans	Creative Commons Attribution 4.0 (CC BY 4.0) — akademik kullanım serbest
Resmi İndirme	https://www.deepsig.ai/datasets / http://opendata.deepsig.ai
Yedek Kaynak	Kaggle: 'RadioML 2016.10a'
IEEE Referansı	O'Shea & West, 'Radio Machine Learning Dataset Generation with GNU Radio', 2016

2.2 İkincil Kaynak — RadioML 2018.01A

Özellik	Detay
Tam Adı	RadioML 2018.01A (GOLD_XYZ_OSC.0001_1024.hdf5)
Üretici	DeepSig Inc. / Timothy J. O'Shea
Yayın Yılı	2018
Üretim Aracı	GNU Radio — geliştirilmiş kanal modeli
Format	HDF5 (.hdf5) — hiyerarşik veri formatı
Boyut	~21 GB (tam veri seti)
Lisans	Creative Commons Attribution 4.0 (CC BY 4.0)
Resmi İndirme	https://www.deepsig.ai/datasets
Bu Projedeki Kullanım	Tam yükleme YAPILMAYACAK — yalnızca yapısal karşılaştırma ve sınırlı test
IEEE Referansı	O'Shea, Roy & Clancy, 'Over-the-Air Deep Learning Based Radio Signal Classification', 2018

2.3 Kaynak Karşılaştırması

Kriter	RadioML 2016.10a	RadioML 2018.01A
Toplam Örnek	220.000	2.555.904
Modülasyon Sınıfı	11	24
Sinyal Uzunluğu	128 örnek/sinyal	1024 örnek/sinyal
SNR Aralığı	−20 dB ila +18 dB	−20 dB ila +30 dB
SNR Adımı	2 dB	2 dB
Kanal Modeli	Temel AWGN + fading	Gelişmiş AWGN + fading + Doppler
Dosya Formatı	.pkl (Python 2)	.hdf5
Boyut	~54 MB	~21 GB
RAM Gereksinimi	~660 MB	>21 GB (tam yükleme için)
Bu projede rolü	TAM EDA + Eğitim + Test	YALNIZCA karşılaştırmalı EDA
Erişilebilirlik (GTX 1650)	Tamamen uygun	Kısmi (alt küme)

Neden iki veri seti?

RadioML 2016.10a, akademik AMC araştırmalarının temel benchmark veri setidir; küçük boyutu ve iyi belgelenmiş yapısı sayesinde öğretici bir platform sunar. 2018.01A ise daha gerçekçi kanal koşullarını ve daha fazla modülasyon tipini barındırır; ancak 21 GB boyutu ve GTX 1650 + 16 GB RAM kısıtları nedeniyle tam eğitim için uygun değildir. İkisi birlikte

kullanılarak 'yönetilebilir geliştirme ortamı' ile 'gerçek dünya karmaşıklığı' arasındaki denge kurulmaktadır.

3. Ham Verinin Toplanması

3.1 Veri İndirme ve Doğrulama Süreci

Aşağıdaki adımlar sırasıyla uygulanmış ve her adım Git commit'i ile belgelenmiştir:

1. **DeepSig resmi sitesinden RML2016.10a_dict.pkl indirildi.**
   - İndirme kaynağı: http://opendata.deepsig.ai/datasets/2016.10/RML2016.10a_dict.pkl.tar.bz2
   - Alternatif: Kaggle üzerinden 'RadioML 2016.10a' arama ile ulaşılabilir.
2. **Dosya bütünlüğü doğrulandı.**
   - Beklenen boyut: ~53-55 MB (sıkıştırılmış)
   - Python ile yüklenip tip ve anahtar sayısı kontrol edildi (bkz. Bölüm 5.1).
3. **RadioML 2018.01A için kısmi erişim planlandı.**
   - Tam indirme (~21 GB) donanım kısıtları nedeniyle yapılmamıştır.
   - DeepSig resmi sitesinde dosya yapısı (HDF5 anahtarları) belgelenmiştir.
   - EDA karşılaştırması için SNR bazlı alt küme örneklemesi planlanmıştır.
4. **Depo dizin yapısı oluşturuldu ve veri dosyaları yerleştirildi.**
   - Git commit: 'add dataset folders and raw data structure'

3.2 Proje Dizin Yapısı

Veri dosyaları aşağıdaki dizin hiyerarşisinde organize edilmektedir:

Depo Dizin Yapısı (GitHub)

```
amc-modulation-classification/
├── data/
│   ├── raw/
│   │   ├── radioml_2016/
│   │   │   └── RML2016.10a_dict.pkl        ← Birincil veri seti
│   │   └── radioml_2018/
│   │       └── (kısmi HDF5 veya alt küme)  ← İkincil (opsiyonel)
│   └── processed/
│       └── (EDA sonrası üretilen temiz veri)
├── notebooks/
│   ├── 01_eda_2016_structure_inspection.ipynb
│   └── 02_eda_2016_full_analysis.ipynb
├── src/
├── app/
├── models/
├── results/
├── docs/
├── requirements.txt
└── README.md
```

4. Etiketleme ve Temizleme Planı

RadioML veri setleri önceden etiketlenmiş (pre-labeled) sentetik veri setleridir. Bu durum, geleneksel veri etiketleme sürecini ortadan kaldırmakta; bunun yerine etiket doğrulama ve veri kalitesi güvencesi (data quality assurance) ön plana çıkmaktadır.

4.1 Etiketleme Yapısı — RadioML 2016.10a

Veri setinde etiket bilgisi, Python sözlük (dictionary) anahtarları aracılığıyla implisit olarak kodlanmıştır. Her anahtar bir (modülasyon_tipi, SNR_değeri) çiftinden oluşmaktadır. Bu yapı sayesinde ayrı bir etiket sütununa gerek kalmamaktadır.

Etiket Bileşeni	Örnek Değerler	Açıklama
Modülasyon tipi (sınıf etiketi)	BPSK, QPSK, QAM16, AM-DSB, ...	11 farklı sınıf — sınıflandırma hedefi
SNR değeri (dB)	−20, −18, −16, ..., +18	20 farklı seviye (2 dB adım)
Anahtar formatı	('BPSK', 0)	(str, int) tuple
Değer formatı	NumPy array (1000, 2, 128)	1000 örnek × 2 kanal × 128 adım

4.2 Model Eğitimi için Etiket Dönüşümü

Model eğitimi sırasında string etiketler (örn. 'BPSK') sayısal indekslere dönüştürülecektir. Bu işlem iki aşamada gerçekleştirilecektir:

Adım	İşlem	Araç	Çıktı
1	Sözlük anahtarlarını listeye dönüştürme	Python dict.keys()	[(mod, snr), ...] listesi
2	Modülasyon etiketlerini sayısala çevirme	sklearn LabelEncoder	0–10 arası tam sayı indeks
3	I/Q dizilerini tek matrise birleştirme	NumPy np.vstack()	X: (220000, 2, 128) array
4	Etiket vektörü oluşturma	NumPy array	y: (220000,) int array
5	SNR bilgisini ayrı vektörde saklama	NumPy array	snr: (220000,) int array

4.3 Veri Kalitesi Kontrol Planı

Aşağıdaki kontroller EDA aşamasında sistematik olarak uygulanacaktır:

Kontrol	Yöntem	Beklenen Sonuç	Durum
Eksik değer kontrolü	np.isnan() / np.isinf()	Hiç NaN veya Inf yok	EDA'da uygulanacak
Sınıf dengesi kontrolü	Sınıf başına örnek sayısı	Her sınıfta 20.000 örnek (11×20×1000)	EDA'da uygulanacak
Sinyal şekli doğrulama	array.shape kontrolü	Tüm değerler (2,128) şeklinde	EDA'da uygulanacak
Değer aralığı kontrolü	min/max istatistikleri	Normalize edilmiş I/Q (-1 ile +1 arası)	EDA'da uygulanacak
Anahtar bütünlüğü	len(keys) == 11×20 = 220	Toplam 220 (mod,snr) çifti	EDA'da uygulanacak
Veri tipi doğrulama	array.dtype kontrolü	float32 veya float64	EDA'da uygulanacak

4.4 Ön İşleme (Preprocessing) Planı

EDA tamamlandıktan sonra model eğitimine hazırlık için aşağıdaki ön işleme adımları uygulanacaktır:

- Normalizasyon: Her sinyal sıfır ortalama ve birim varyansa normalize edilecektir (z-score normalization). Bu adım CNN'lerin eğitim stabilitesini artırır.
- Eğitim/Doğrulama/Test bölümlemesi: %70 / %15 / %15 oranında stratified split uygulanacaktır. Stratified split, her sınıfın tüm bölümlerde dengeli temsil edilmesini garanti eder.
- SNR bazlı bölümleme seçeneği: Modelin gerçek dünya performansını simüle etmek için düşük SNR aralığı (−20 dB ila −2 dB) test seti olarak ayrılabilir.
- Tensor dönüşümü: NumPy dizileri PyTorch tensörlerine (torch.FloatTensor) dönüştürülecektir.
- Veri yükleyici (DataLoader): batch_size=128 ile mini-batch eğitim için PyTorch DataLoader kullanılacaktır.

Önemli Not — Veri Temizliği

RadioML 2016.10a tamamen sentetik ve kontrollü koşullarda üretilmiş bir veri setidir. Bu nedenle gerçek dünya veri setlerinde karşılaşılan sorunların (eksik değerler, aykırı değerler, tutarsız etiketler, çift kayıtlar) büyük çoğunluğu bu veri setinde mevcut değildir. Bununla birlikte, NaN/Inf kontrolü ve değer aralığı doğrulaması iyi mühendislik pratiği gereği EDA'da eksiksiz uygulanacaktır.

5. Veri Sözlüğü

Bu bölüm, projede kullanılan her iki veri setinin tüm değişkenlerini, yapısal bileşenlerini ve teknik terimlerini tanımlamaktadır.

5.1 RadioML 2016.10a — Yapısal Bileşenler

Bileşen	Tür	Boyut / Değer	Açıklama
dataset	Python dict	220 anahtar	Tüm veri setini tutan ana sözlük nesnesi
anahtar (key)	tuple (str, int)	(modülasyon, SNR)	Her giriş için benzersiz tanımlayıcı
değer (value)	NumPy ndarray	(1000, 2, 128)	Bir (mod, SNR) çifti için 1000 sinyal
I kanalı	float	(1000, 128)	Her sinyalin In-phase (gerçek) bileşeni (axis 1, index 0)
Q kanalı	float	(1000, 128)	Her sinyalin Quadrature (sanal) bileşeni (axis 1, index 1)
zaman adımı	int	0–127 (toplam 128)	Örnekleme noktası; tek sinyal içindeki zaman indeksi
örnek indeksi	int	0–999 (toplam 1000)	Aynı (mod, SNR) koşulu altındaki farklı sinyal realizasyonu

5.2 Modülasyon Sınıfları — Tam Sözlük

Etiket (String)	Sayısal İndeks	Tam Adı	Modülasyon Ailesi
AM-DSB	0	Amplitude Modulation — Double Sideband	Analog AM
AM-SSB	1	Amplitude Modulation — Single Sideband	Analog AM
WBFM	2	Wideband Frequency Modulation	Analog FM
BPSK	3	Binary Phase Shift Keying	Dijital PSK
QPSK	4	Quadrature Phase Shift Keying	Dijital PSK
8PSK	5	8-ary Phase Shift Keying	Dijital PSK
16QAM	6	16-ary Quadrature Amplitude Modulation	Dijital QAM
64QAM	7	64-ary Quadrature Amplitude Modulation	Dijital QAM
CPFSK	8	Continuous Phase Frequency Shift Keying	Dijital FSK

Etiket (String)	Sayısal İndeks	Tam Adı	Modülasyon Ailesi
GFSK	9	Gaussian Frequency Shift Keying	Dijital FSK
PAM4	10	4-ary Pulse Amplitude Modulation	Dijital PAM

Not: Sayısal indeks değerleri sklearn.preprocessing.LabelEncoder ile alfabetik sıralama sonucu atanacaktır. Yukarıdaki değerler tahmini sırayı göstermekte olup EDA aşamasında kesinleştirilecektir.

5.3 SNR Değerleri Sözlüğü

SNR (dB)	Gürültü Kategorisi	Beklenen Sınıflandırma Zorluğu	Notlar
−20, −18	Çok yüksek gürültü	Çok zor — neredeyse imkânsız	Çoğu model rastgele tahmin düzeyinde
−16, −14, −12	Yüksek gürültü	Zor — sınırlı başarı	Sinyal gürültüde gömülü
−10, −8, −6	Orta-yüksek gürültü	Orta güçlük	Bazı modülasyonlar ayırt edilebilir
−4, −2, 0	Orta gürültü	Makul başarı beklenir	CNN'lerin güçlenmeye başladığı aralık
+2, +4, +6	Düşük gürültü	İyi başarı	Çoğu model %70+ doğruluk gösterir
+8, +10, +12	Çok düşük gürültü	Yüksek başarı	Derin öğrenme %85+ ulaşır
+14, +16, +18	Temiz sinyal	En yüksek başarı	Sınır: analog modülasyonlar (AM/FM) hâlâ zor

5.4 Teknik Terimler Sözlüğü

Terim	Tanım
I/Q Sinyali	In-phase (I) ve Quadrature (Q) bileşenlerinden oluşan karmaşık tabanlı sinyal temsili. I gerçel, Q sanal kısma karşılık gelir. Birlikte bir RF sinyalinin genlik ve fazını tam olarak betimler.
SNR (Signal-to-Noise Ratio)	Sinyal-Gürültü Oranı. dB cinsinden ifade edilir. Yüksek SNR → temiz sinyal; düşük/negatif SNR → gürültüye gömülü sinyal.
Modülasyon	Veri aktarımı için taşıyıcı sinyalin (genlik, faz veya frekans) değiştirilmesi işlemi. AMC bu değişim tipini otomatik tanımayı hedefler.

Terim	Tanım
AWGN	Additive White Gaussian Noise — Katkısal Beyaz Gauss Gürültüsü. Tüm frekans bileşenlerinde eşit güçte rastgele gürültü modeli.
GNU Radio	RF sinyal üretimi ve işleme için açık kaynak yazılım tabanlı radyo geliştirme platformu. RadioML veri setleri bu araçla üretilmiştir.
Pickle (.pkl)	Python nesne serileştirme formatı. RadioML 2016.10a bu formatta dağıtılmaktadır; latin1 kodlaması ile yüklenmelidir.
HDF5 (.hdf5)	Hiyerarşik Veri Formatı v5. Büyük bilimsel veri setleri için optimize edilmiştir. RadioML 2018.01A bu formattadır.
Baseline Model	Karşılaştırma için kullanılan en basit referans model. Bu projede Random Forest baseline olarak seçilmiştir.
AMC	Automatic Modulation Classification — Otomatik Modülasyon Sınıflandırması. Bu projenin çözmeye çalıştığı temel problemdir.
Stratified Split	Sınıf dağılımını koruyarak veri setini eğitim/doğrulama/test olarak bölen yöntem. Dengesiz veri setlerinde kritik önem taşır.
LabelEncoder	sklearn kütüphanesinde string etiketleri (örn. 'BPSK') sayısal indekslere (örn. 3) dönüştüren araç.
DataLoader	PyTorch'ta mini-batch veri besleme, karıştırma (shuffle) ve paralel yükleme işlevlerini sağlayan sınıf.

6. Veri Envanteri

Bu bölüm, dersin Hafta 2 teslim gereksinimine karşılık gelen resmi veri envanterini sunmaktadır.

6.1 Veri Seti Envanteri

Alan	RadioML 2016.10a	RadioML 2018.01A
Kaynak Kuruluş	DeepSig Inc.	DeepSig Inc.
Lisans	CC BY 4.0	CC BY 4.0
Erişim Yöntemi	Doğrudan indirme (.pkl)	Doğrudan indirme (.hdf5)
Boyut (disk)	~54 MB	~21 GB
Boyut (RAM)	~220 MB	>21 GB (tam)
Sınıf Sayısı	11 modülasyon tipi	24 modülasyon tipi
Toplam Örnek	220.000	2.555.904
Sinyal Şekli	(2, 128)	(2, 1024)
SNR Aralığı	−20 dB ila +18 dB	−20 dB ila +30 dB
Etiket Formatı	Sözlük anahtarı (mod, SNR)	HDF5 dataset 'Y' (one-hot)
Eksik Değer	Beklenen: Yok (sentetik)	Beklenen: Yok (sentetik)

Alan	RadioML 2016.10a	RadioML 2018.01A
Kişisel Veri	Yok — KVKK dışı	Yok — KVKK dışı
Veri Kalitesi	Çok yüksek (kontrollü üretim)	Çok yüksek (kontrollü üretim)
Proje Rolü	Birincil — tam eğitim + test	İkincil — karşılaştırmalı EDA
İndirme Tarihi	[Öğrenci dolduracak]	[Öğrenci dolduracak / Kısmi]
Depolama Yolu	data/raw/radioml_2016/	data/raw/radioml_2018/

6.2 Git Commit Planı (Hafta 2)

Commit No	Commit Mesajı	İçerik
1	init: project structure and README	Dizin yapısı, README.md, requirements.txt
2	data: add radioml 2016 dataset to raw folder	RML2016.10a_dict.pkl dosyasının eklenmesi
3	docs: add data inventory phase 2 report	Bu raporun /docs klasörüne eklenmesi
4	docs: add data dictionary for radioml datasets	Veri sözlüğünün /docs klasörüne eklenmesi
5	feat: verify dataset loading and structure	Veri setini açıp anahtar/şekil doğrulaması yapan .py script

6.3 Requirements — Teknik Bağımlılıklar

requirements.txt içeriği

numpy>=1.24.0pandas>=2.0.0matplotlib>=3.7.0seaborn>=0.12.0scikit-learn>=1.3.0torch>=2.0.0h5py>=3.9.0 # RadioML 2018.01A HDF5 okuma içinjupyter>=1.0.0streamlit>=1.28.0 # Demo aşaması içintqdm>=4.65.0 # İlerleme çubuğu

7. Sonraki Adım — Faz 3: EDA

Veri toplama ve etiketleme planı tamamlandıktan sonra bir sonraki fazda (Faz 3 — EDA) aşağıdaki analizler gerçekleştirilecektir:

EDA Görevi	Araç	Çıktı
Veri setini yükle ve yapısal doğrulama yap	pickle, NumPy	Shape, dtype, key listesi
Sınıf ve SNR dağılımını analiz et	Matplotlib, Seaborn	Bar chart, heatmap
Örnek I/Q dalga biçimlerini görselleştir	Matplotlib	Waveform grafikleri (her sınıf için)

EDA Görevi	Araç	Çıktı
Sinyal güç ve istatistiksel özetini çıkar	NumPy	Mean, std, min, max tablosu
Konstelasyon diyagramı (IQ scatter plot)	Matplotlib scatter	Her modülasyon için IQ uzayı
2016 vs 2018 yapısal karşılaştırması	Tablo + grafik	Karşılaştırma raporu

8. Sonuç

Bu Faz 2 raporu, AMC projesinin veri toplama ve etiketleme aşamasını eksiksiz belgelemiştir. Birincil veri kaynağı (RadioML 2016.10a) ve ikincil kaynak (RadioML 2018.01A) tanımlanmış, her iki veri setinin yapısı karşılaştırmalı olarak incelenmiş, etiketleme yapısı ve ön işleme planı ortaya konmuş, kapsamlı bir veri sözlüğü hazırlanmış ve resmi veri envanteri oluşturulmuştur.

RadioML 2016.10a'nın tamamen sentetik ve önceden etiketlenmiş yapısı, manuel etiketleme yükünü ortadan kaldırmaktadır. Bununla birlikte, veri kalitesi güvencesi (NaN/Inf kontrolü, şekil doğrulama, sınıf dengesi analizi) EDA aşamasında sistematik biçimde uygulanacaktır. Proje, dersin öngördüğü CRISP-DM uyumlu AI yaşam döngüsü çerçevesinde yürütülmektedir.